

Clasificación del Riesgo de Inundación por Parroquia

Provincia de Los Ríos, Ecuador

Facultad De Ciencias Matemáticas Y Físicas

Carrera:

Ciencia de datos e inteligencia artificial

Curso:

CDDEIA-ELMA-4-1

Materia:

Aprendizaje automático

Docente:

Ing. Darwin Rodríguez Merchán, MSc.

Integrantes del grupo D:

Parrales Moreno Kathia

Barros Rubio Sharick

Cruz Huacon Anthony

Velez Landaverea Andres

Iñiguez Ruiz Juan

Zavala Betancourt Jeanpaul

8 de julio de 2026

1. Introducción y contextualización

Ecuador presenta una alta vulnerabilidad frente a eventos hidrometeorológicos extremos, especialmente inundaciones, que se intensifican en las temporadas lluviosas de la Costa. La provincia de Los Ríos es, según el SNGRE, una de las zonas históricamente más afectadas por desbordamientos de ríos entre 2019 y 2023.

Este proyecto propone un modelo de clasificación supervisada que asigna a cada una de las 30 parroquias de la provincia una categoría de riesgo de inundación (bajo, medio, alto), integrando variables climáticas, topográficas y socio-territoriales, con el fin de apoyar decisiones de gestión de riesgo a nivel local.

2. Descripción de los datos y su origen

El conjunto de datos se construyó unificando fuentes oficiales abiertas por código DPA de parroquia: precipitación acumulada anual (Open-Meteo Archive API), altitud media del centroide (Open-Meteo Elevation API), distancia mínima a ríos principales (HydroSHEDS), densidad poblacional y porcentaje de población urbana (INEC, Censo 2022), además de dos variables derivadas: un índice de pendiente relativa calculado a partir de la altitud, y un ratio de precipitación en temporada lluviosa frente a temporada seca, obtenido de series diarias.

La variable objetivo (**riesgo**) no proviene de ningún dataset preetiquetado: se construyó mediante un sistema de puntuación multicriterio que combina umbrales de precipitación, altitud, cercanía a ríos, densidad poblacional y pendiente, alineado con el Marco de Sendai para la Reducción del Riesgo de Desastres 2015-2030.

3. Metodología

Tras unificar y limpiar los datos (verificación de nulos, duplicados y formatos), se realizó un análisis exploratorio que incluyó estadísticas descriptivas, boxplots por nivel de riesgo, histogramas, mapa de calor de correlaciones y un análisis temporal con promedio móvil de 30 días y mapa de calor mensual de precipitación.

Para el modelado se dividió el conjunto en entrenamiento y prueba (75/25, estratificado) y se entrenaron cuatro modelos: Regresión Logística (base), Árbol de Decisión, un Ensamble por votación (Regresión Logística + Árbol de Decisión + Random Forest) y un Random Forest optimizado mediante **GridSearchCV**. La evaluación se realizó con Precisión, Recall, F1-score y AUC-ROC (estrategia One-vs-Rest).

Figura 1: Distribución de variables por nivel de riesgo - Los Ríos




Figura 2: Histogramas de variables predictoras - Los Ríos





Figura 3: Mapa de correlación entre variables predictoras



4. Resultados obtenidos

La Tabla 1 resume el desempeño de los cuatro modelos sobre el conjunto de prueba.

Modelo	Precisión	Recall	F1-score	AUC-ROC
Regresión Logística	0.77	0.77	0.77	0.95
Árbol de Decisión	0.57	0.67	0.61	0.72
Ensamble (RL+DT+RF)	0.57	0.67	0.61	0.95
RF Optimizado (GridSearch)	0.57	0.67	0.61	0.90

Cuadro 1: Comparación de métricas (macro-promedio) entre modelos.

La Regresión Logística obtuvo el mejor desempeño global, alcanzando un Recall macro de 0.77 frente al 0.67 de las alternativas basadas en árboles y ensambles. En el ámbito de la gestión de riesgos, el costo humano y material de un *falso negativo* (omitir la predicción de una zona de alto riesgo) supera con creces el de un *falso positivo*. Bajo este fundamento metodológico, el Recall se priorizó como la métrica crítica de selección.

Consecuentemente, la (**Regresión Logística**) fue consagrada como el modelo ganador para producción. El archivo serializado `modelo.pkl` y el flujo operativo del sistema corresponden estrictamente a este algoritmo estadístico, garantizando un despliegue matemáticamente coherente con las métricas observadas.

5. Discusión y limitaciones

A pesar de la robustez del modelo seleccionado, el análisis riguroso del pipeline revela limitaciones metodológicas esenciales que deben ser reconocidas:

- **Severo desbalance de clases:** El conjunto de datos (30 parroquias) presenta una distribución asimétrica real. La clase “bajo riesgo” constituye la minoría extrema con solo 3 parroquias (10.0 %), seguida por la clase “alto riesgo” con 8 parroquias (26.7 %), concentrándose la mayoría absoluta en “medio riesgo” (19 parroquias, 63.3 %). Este desbalance restringe la capacidad de generalización en las fronteras de los extremos analíticos, aun aplicando hiperparámetros de penalización como `class_weight='balanced'`.
- **Colinealidad perfecta en ingeniería de variables:** Como se evidencia en la Figura 3, la correlación entre `altitud_m` y `pendiente_idx` es exactamente 1,00. Esto ocurre porque el índice de pendiente relativa fue estructurado mediante un reescalado lineal directo de la elevación estándar $\frac{\text{altitud} - \text{alt}_{\min}}{\text{alt}_{\max} - \text{alt}_{\min}} \times 10$. En modelos lineales paramétricos como la Regresión Logística, la presencia de multicolinealidad perfecta duplica la información estadística y desestabiliza los coeficientes, impidiendo aislar el efecto físico e individual de la pendiente real del terreno.
- **Validación Externa y Sesgo de Diseño:** Las métricas sobresalientes de AUC-ROC (0,90 – 0,95) responden parcialmente a que la variable objetivo fue construida de forma sintética a partir de umbrales fijos sobre los mismos predictores. Aunque la introducción de ruido gaussiano ($\sigma = 0,6$) mitigó eficazmente el riesgo de una fuga de información perfecta, el patrón subyacente sigue una lógica paramétrica conocida, limitando la validez externa del modelo ante dinámicas territoriales empíricas no controladas.

Adicionalmente, desde la perspectiva de la infraestructura física y despliegue, el sistema web depende de un archivo GeoJSON externo sujeto a disponibilidad pública y al acoplamiento estricto del código DPA. Asimismo, el alojamiento en el entorno gratuito de *PythonAnywhere* limita la concurrencia operativa y la persistencia a largo plazo de la plataforma.

6. Conclusiones finales

El proyecto integró con éxito un ciclo completo de ciencia de datos, desde la unificación y tratamiento de variables geográficas hasta el despliegue del servicio. Bajo un enfoque de parsimonia científica, se concluye que ante conjuntos de datos pequeños, acotados y altamente desbalanceados, un estimador simple e interpretable como la Regresión Logística supera a estructuras complejas como *Random Forest*, mitigando el riesgo de sobreajuste y ofreciendo el Recall más apto para salvaguardar la toma de decisiones en el sector público.

Como trabajo futuro prioritario para escalar la madurez del sistema, se propone:

1. Sustituir el índice de transformación lineal por un Modelo Digital de Elevación (DEM) real para capturar la geomorfología genuina del suelo sin multicolinealidad.
2. Cruzar la variable predictiva sintética con registros históricos empíricos de inundaciones validados por el SNGRE.
3. Incrementar la representatividad estadística expandiendo el alcance del estudio hacia un marco interprovincial o regional.

7. Código fuente del análisis de los datos

El código fuente interactivo con la implementación del análisis de datos, el entrenamiento de los modelos y las evaluaciones se encuentra disponible en el siguiente enlace: <https://colab.research.google.com/drive/1Tgg5C4jFLlEsXRzts72ux0JwvCpzs0b6?usp=sharing>.